

MODELO DE REGRESIÓN LINEAL MÚLTIPLE DE VARIABLE DE RESPUESTA RENDIMIENTO DE VEHÍCULO Y LAS VARIABLES EXPLICATIVAS TAMAÑO DE MOTOR, POTENCIA, DIMENSIONES FÍSICAS Y PESO DEL VEHÍCULO.

Introducción.

En la industria automotriz contemporánea, la eficiencia energética y el consumo de combustible se han consolidado como criterios fundamentales de competitividad, sustentabilidad y decisión de compra. El rendimiento de un vehículo, medido comúnmente en millas por galón (MPG), no es el resultado de un factor aislado, sino de la interacción compleja entre variables mecánicas, de diseño estructural y de potencia. El presente estudio se basa en el análisis de un conjunto de datos técnicos que recopila características intrínsecas de diversos modelos de automóviles, tales como el tamaño del motor (pulgadas cúbicas), la potencia (caballos de fuerza), las dimensiones físicas (ancho y largo en pulgadas) y el peso total expresado en toneladas. A través de este registro, se busca entender cómo la configuración de ingeniería de un vehículo impacta directamente en su eficiencia en el consumo de combustible.

El objetivo principal de este trabajo es desarrollar y evaluar un modelo de regresión lineal múltiple que explique el comportamiento de la variable de respuesta "Rendimiento" (Millas por Galón) en función de las variables predictoras disponibles (Tamaño Motor, Potencia Motor, Ancho Auto, Largo Auto y Peso Auto).

Metodología.

Con el propósito de caracterizar las variables del estudio se calcularon estadísticos de posición y dispersión: media, mediana, desviación estándar, mínimo y máximo; complementados con diagramas de caja para identificar posibles valores atípicos y diagramas de dispersión para explorar la relación bivariada entre cada predictor y la variable respuesta. Esta etapa exploratoria orientó la selección de variables candidatas al modelo.

La asociación entre cada predictor y el Rendimiento se evaluó mediante correlación parcial, la cual permite cuantificar la contribución única de cada variable eliminando el efecto lineal de las demás. Con base en este criterio se procedió a la construcción del modelo de regresión lineal múltiple de la forma:

$$\hat{Y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_s X_{si} + \varepsilon_i$$

donde $\hat{Y}$ representa el Rendimiento estimado en millas por galón y los x_j denotan las variables predictoras seleccionadas. Los parámetros se estimaron por mínimos cuadrados ordinarios (MCO). La significancia individual de cada coeficiente se evaluó mediante su

p-valor asociado. La bondad de ajuste se cuantificó a través del coeficiente de determinación ajustado R^2_{adj} .

Con base en este criterio se procedió a la construcción del modelo de regresión lineal múltiple, aplicando el procedimiento de Eliminación hacia atrás para la selección de variables: partiendo del modelo completo con los cinco predictores disponibles, se removieron iterativamente aquellas variables cuyo estadístico F parcial no superó el umbral de significancia $\alpha = 0.05$, hasta retener únicamente los predictores con aportación explicativa estadísticamente justificada.


Previo a la selección del modelo final se realizó un diagnóstico de observaciones atípicas mediante residuos estandarizados, eliminando aquellas observaciones cuyos residuos superaron el umbral $|e^*_i| > 3$. Sobre el conjunto depurado se verificaron los supuestos del modelo: linealidad mediante el gráfico de residuos vs. valores ajustados, normalidad de los errores mediante la prueba de Shapiro-Wilk y el Q-Q plot, y homocedasticidad mediante un diagnóstico bidimensional que contrasta los residuales del modelo contra los valores ajustados, complementado con la prueba formal de Breusch-Pagan, cuya hipótesis nula postula varianza constante de los errores; el rechazo de dicha hipótesis se evalúa con un nivel de significancia $\alpha = 0.05$.

Resultados.

1.1. Estadística descriptiva y correlación simple

El conjunto de datos comprende 152 observaciones completas, sin valores faltantes, con cinco variables predictoras continuas y una variable respuesta discreta: el Rendimiento en millas por galón (MPG). Los rangos revelan asimetrías importantes: Tamaño del Motor y Potencia presentan valores máximos (8.0 L y 450 HP) muy alejados de sus respectivas medianas (3.0 L y 175 HP), lo que anticipa la presencia de observaciones extremas. El Peso oscila entre 2.24 y 5.57 toneladas con distribución asimétrica, mientras que Ancho es la variable más compacta. Rendimiento toma valores enteros en [15, 33] MPG con media y mediana prácticamente coincidentes (23.7 y 24), sugiriendo simetría aproximada; su naturaleza discreta será una limitación al evaluar la normalidad de los residuos.


Figura 1. Diagramas de caja por variable.



Los diagramas de caja confirman observaciones atípicas en Tamaño, Potencia, Peso y Largo. El caso más extremo corresponde a un automóvil con motor de 8.0 L y 450 HP, seguido de un segundo vehículo con aproximadamente 6.0 L y 350 HP. En Peso se detectan tres valores superiores a 5.0 toneladas; en Largo, un valor máximo de 224.5 pulgadas. Estas observaciones serán retomadas en la etapa de diagnóstico del modelo.

Los diagramas de dispersión permiten una primera aproximación a las relaciones bivariadas con Rendimiento. Peso muestra la tendencia negativa más clara y consistente. Tamaño exhibe un patrón similar aunque con mayor dispersión en valores extremos. Potencia, Ancho y Largo presentan nubes dispersas sin tendencia lineal definida a nivel individual; no obstante, su comportamiento bajo control multivariado se evaluará mediante correlación parcial.

Figura 2. Diagramas de dispersión predictores vs. Rendimiento.



Correlación de las variables predictoras con la variable de respuesta.

La siguiente tabla presenta las correlaciones de las variables predictoras (LargoAuto, AnchoAuto, Potencia Motor, Tamaño Motor y Peso Auto) para evaluar el grado en que cada

una explica la variabilidad del rendimiento.

Tabla 1. Correlación con variable Rendimiento	
Variable	Coeficiente de correlación (r):
Largo Auto	-0.397
Ancho Auto	-0.581
Potencia Motor	-0.597
Tamaño Motor	-0.743
Peso Auto	-0.825

Se observa que todas las variables predictoras analizadas presentan una correlación lineal negativa con respecto a la variable rendimiento. Esto indica una relación inversamente proporcional: a mayores dimensiones, potencia o peso del vehículo, menor es su rendimiento de combustible.

Al evaluar la fuerza de estas relaciones, se pueden categorizar de la siguiente manera:

Correlación negativa fuerte a muy fuerte: El Peso Auto ($r = -0.825$) y el Tamaño Motor ($r = -0.743$) son las variables que muestran la asociación más robusta con la caída del rendimiento. El peso, en particular, se perfila como el predictor lineal más crítico.

Correlación negativa moderada a fuerte: La Potencia Motor ($r = -0.597$) y el Ancho Auto ($r = -0.581$) también muestran un impacto lineal considerable y negativo sobre el rendimiento.

Correlación negativa moderada-débil: El Largo Auto ($r = -0.397$) es la variable con la asociación más débil del grupo, sugiriendo que la longitud por sí sola influye menos en el rendimiento que el volumen del motor o la masa total del vehículo.

1.2. Correlación parcial con la variable respuesta

Para comprobar el valor predictivo de las variables explicativas de manera individual con respecto a la variable explicada, se realiza una prueba de correlación parcial. Esta prueba permite cuantificar la aportación única de cada variable predictora sobre el Rendimiento, eliminando el efecto lineal compartido con las demás variables. A diferencia de la correlación simple, la correlación parcial aísla la relación directa entre cada predictor y la respuesta, lo que permite identificar qué variables tienen valor explicativo real más allá de sus interrelaciones. Esto a su vez, complementará la elección de variables finales, en la sección *Selección de variables* se tomará la decisión final sobre qué variables se utilizarán en el modelo final.

En la tabla 2, se muestran los resultados de la correlación parcial considerando todas las variables.

Tabla 2. Correlación parcial con respecto a Rendimiento		
Variable	Corr. Parcial.	p-valor
Largo Auto	0.2790	0.0006
Ancho Auto	-0.0016	0.9842
Potencia Motor	0.0531	0.5215
Tamaño Motor	-0.2895	0.0004
Peso Auto	-0.6354	0.0000

A partir de las métricas obtenidas, se desprenden los siguientes hallazgos analíticos concluyentes:

- **Peso Auto ($r = -0.6354$):** Se consolida como el predictor determinante y de mayor peso específico del modelo. Exhibe una correlación parcial negativa fuerte. Esto demuestra que, manteniendo constantes todas las demás características físicas y del motor (como el largo, ancho o potencia), el incremento en la masa vehicular genera de forma directa y unívoca una caída severa en el rendimiento de combustible.
- **Tamaño Motor ($r = -0.2895$):** Presenta una correlación parcial negativa moderada. Al aislar estadísticamente el efecto del peso y las dimensiones, se confirma de manera independiente que una mayor cilindrada del motor incrementa el consumo energético per se. Su relevancia matemática justifica plenamente su inclusión como variable explicativa complementaria en el sistema predictivo.
- **Largo Auto ($r = 0.2790$):** Presenta un cambio de signo respecto a su correlación simple ($r = -0.397$). Este fenómeno, conocido como supresión, ocurre cuando una variable comparte varianza con otros predictores, en este caso Peso Auto y Tamaño Motor, lo que distorsiona su relación aparente con el Rendimiento. Al controlar estadísticamente el efecto de dichas variables, el efecto propio del Largo Auto sobre el Rendimiento resulta positivo: vehículos más largos tienden a ser aerodinámicamente más eficientes cuando se mantiene constante su peso y cilindrada.
- **Ancho Auto ($r = -0.0016$) y Potencia Motor ($r = 0.0531$):** Ambas correlaciones parciales son bajas y por ende, imperceptibles con el rendimiento.

1.3. Modelo inicial con todos los predictores

Ajuste de modelo con todas las variables predictoras

En la siguiente tabla se visualiza el modelo ajustado, considerando todas las variables predictoras para establecer un modelo de regresión lineal múltiple. Dicho modelo tiene un $R^2_{adj} = 0.733$ pero con coeficientes que no son estadísticamente diferentes de cero (Potencia Motor y Ancho Auto)

Tabla 3. Modelo ajustado con todas las variables predictoras.

Variable	Coeficiente (β)	Valor p
Constante (Intercepto)	30.6998	< 0.001
Tamaño Motor	-1.3532	< 0.001
Potencia Motor	0.0035	0.522
Ancho Auto	-0.0016	0.984
Peso Auto	-4.5189	< 0.001
Largo Auto	0.0637	0.001

1.4. Selección de variables

La selección de variables siguió el procedimiento de Eliminación hacia atrás descrito en la Parte I: partiendo del modelo completo con los cinco predictores, se evaluó el estadístico F parcial de cada variable bajo control multivariado y se removieron sucesivamente aquellas cuyos coeficientes no resultaron estadísticamente significativos ($\alpha = 0.05$). La Tabla X resume los pasos del proceso.

Tabla 4. Pasos de la Eliminación hacia atrás.

Paso	Acción	F parcial	p-valor	Variables en el modelo
1	Sale: Ancho Auto	0.0004	0.984	Tamaño, Potencia, Largo, Peso
2	Sale: Potencia Motor	0.4175	0.519	Tamaño, Largo, Peso

Este resultado es consistente con los hallazgos previos: las correlaciones parciales de la sección 1.2 ya anticipaban que Ancho Auto ($r = -0.0016$, $p = 0.984$) y Potencia Motor ($r = 0.0531$, $p = 0.522$) carecían de valor explicativo bajo control multivariado, y el modelo completo de la sección 1.3 confirmó la no significancia de sus coeficientes. Las tres variables predictoras finales son: Tamaño Motor, Peso Auto y Largo Auto.

Tabla 5. Modelo ajustado con “Tamaño Motor”, “Peso Auto” y “Largo Auto”

Variable	Coefficiente (β)	Valor p
Constante (Intercepto)	31.0628	< 0.001
Peso Auto	-4.5274	< 0.001
Tamaño motor	-1.1855	< 0.001
Largo Auto	0.0620	<0.001

Para este escenario, se tiene un modelo con un $R^2_{adj} = 0.736$ y coeficientes estadísticamente diferentes de cero, lo que pareciera un modelo óptimo, sin embargo, resta realizar la identificación y tratamiento de valores atípicos, así como la validación de los supuestos del modelo.

1.5. Detección y tratamiento de valores atípicos

Para la detección de outliers se utiliza el criterio de Residuales Estandarizados con la finalidad de detectar observaciones atípicas que se alejen de la tendencia central -3 o 3 desviaciones estándar. De los cuales se localizaron los siguientes registros.

Tabla 6. Identificación de Outliers.

Dato	Peso Auto	Tamaño Motor	Rendimiento	Largo Auto
40	3.557	2.5	19	215
64	3.045	2.5	17	152
104	3.217	3.3	18	196.1

Con base en este diagnóstico, se procedió a la remoción estratégica de estos tres registros. Teniendo en total, 149 observaciones para la postulación de un modelo de Regresión Lineal.

1.6. Modelo final e interpretación de coeficientes

En consecuencia, se decide ajustar un modelo de regresión lineal considerando la eliminación de los outliers. El valor de los parámetros con sus respectivos valores p lo obtenemos en la siguiente tabla. El valor de $R^2_{adj} = 0.784$.

Tabla 7. Modelo ajustado sin outliers con su interpretación

Variable	Coefficiente (β)	Valor p	Interpretación
Constante (Intercepto)	30.9495	< 0.001	Representa el valor teórico esperado del <i>Rendimiento</i> cuando todas las variables explicativas del modelo (<i>Tamaño Motor</i> , <i>Peso Auto</i> y <i>Largo Auto</i>) son estadísticamente iguales a cero.
Peso Auto	-4.5395	< 0.001	Manteniendo constantes el <i>Tamaño Motor</i> y el <i>Largo Auto</i> , por cada unidad de incremento en el <i>Peso</i>

			<i>auto</i> , el <i>Rendimiento</i> del vehículo disminuye en promedio 4.5395 unidades
Tamaño Motor	-1.2317	< 0.001	Manteniendo constantes el <i>Peso Auto</i> y el <i>Largo Auto</i> , por cada unidad que aumente el <i>Tamaño Motor (cilindrada)</i> , el <i>Rendimiento</i> se reduce en promedio 1.2317 unidades
Largo Auto	0.0643	<0.001	Manteniendo constantes el <i>Tamaño Motor</i> y el <i>Peso Auto</i> , por cada unidad de incremento en el <i>Largo Auto</i> , el <i>Rendimiento</i> del vehículo aumenta en promedio 0.0643 unidades


Los parámetros estimados fueron significativamente diferentes de cero y, además, el R^2_{adj} aumentó en comparación del modelo que consideraba a los outliers. Lo que nos indica, un modelo más óptimo para describir y predecir el Rendimiento con respecto a las variables predictoras “Tamaño Motor”, “Peso Auto” y “Largo Auto”.

1.7. Validación de supuestos

- **Supuesto de Linealidad**

El gráfico de residuales contra valores ajustados (e_i vs. $\hat{Y}_i$) no exhibe patrón sistemático alguno: los puntos se distribuyen aleatoriamente en una banda horizontal simétrica alrededor del cero a lo largo de todo el rango predictivo, sin curvatura ni tendencia que sugiera una relación no lineal omitida. El supuesto de linealidad se considera satisfecho.

Figura 3. Gráfico de residuales contra valores ajustados.




- **Errores Residuales se comportan de manera normal.**

Para garantizar que los errores se distribuyen de manera normal, se aplicó la prueba de significancia de Shapiro-Wilk. El análisis arrojó un valor p de 0.346, lo que significa que no existe evidencia estadística suficiente para rechazar la hipótesis nula, la cual postula que los residuos siguen una distribución normal.

En la Figura 4 se visualiza el comportamiento de estos errores mediante un histograma de frecuencias (que muestra su forma y simetría) y un gráfico de cuantil-cuantil (Q-Q plot). Ambos análisis gráficos respaldan y confirman de manera visual los resultados obtenidos en la prueba de Shapiro-Wilk.

Figura 4. Comportamiento de errores mediante un histograma de frecuencias y un gráfico de cuantil-cuantil (Q-Q plot)




- **Homocedasticidad (Varianza Constante)**

El supuesto de homocedasticidad exige que la varianza de los errores residuales permanezca constante e independiente de los valores estimados por el modelo y de las variables predictoras (*Peso Auto*, *Tamaño Motor* y *Largo Auto*). El cumplimiento de esta condición es crítico en el estimador de Mínimos Cuadrados Ordinarios (MCO), ya que garantiza que los errores estándar de los coeficientes no estén sesgados, preservando la validez de los intervalos de confianza y de las pruebas de significancia individual.

Para evaluar este supuesto en el modelo definitivo ($n = 149$), se realizó un diagnóstico bidimensional contrastando los *Valores Predichos* frente a los *Residuales del Modelo* (Figura 5).

Figura 5. Diagnóstico gráfico de homocedasticidad mediante dispersión de residuales



Como se aprecia en la Figura 5, la dispersión de las unidades muestrales no exhibe patrones geométricos sistemáticos latentes. Los errores se distribuyen de manera puramente aleatoria en una banda horizontal simétrica alrededor de la recta de referencia cero. No se observan evidencias de heterocedasticidad, tales como un ensanchamiento de la varianza en las zonas de alto rendimiento (forma de cono o megáfono) ni curvaturas que sugieran un error de especificación, confirmando que la estabilidad de la varianza es uniforme a lo largo de todo el espectro predictivo.

Para complementar el diagnóstico gráfico, se aplicó la prueba de Breusch-Pagan. El reportado valor-p es 0.5700, por lo que se cumple que $p > 0.05$ y se concluye que no existe evidencia estadística suficiente para rechazar la hipótesis nula de varianza constante. Ambos análisis, gráfico y formal, confirman el cumplimiento del supuesto de homocedasticidad.

- **Ausencia de Error de Medición en las Variables Predictoras (Regresores)**

Dada la naturaleza del conjunto de datos técnicos analizados ($n = 149$), donde los predictores corresponden a especificaciones de ingeniería homologadas y estandarizadas de la industria automotriz: tales como el Peso Auto (toneladas), Tamaño Motor (litros/pulgadas cúbicas) y Largo Auto (pulgadas). El cumplimiento de este supuesto se sustenta bajo un criterio analítico e institucional. Al tratarse de dimensiones físicas estructurales y de cubicaje motriz determinadas mediante instrumentos de precisión industrial durante los procesos de manufactura y certificación técnica de los vehículos, la varianza del error de medición se asume asintóticamente cercana a cero.

1.8. Coeficientes estandarizados

En un modelo de regresión lineal múltiple donde las variables explicativas se expresan en dimensiones físicas distintas: Peso Auto en toneladas, Tamaño Motor en pulgada cúbica y Largo Auto en unidades de longitud, los coeficientes parciales ordinarios (β) no permiten establecer comparaciones directas de impacto. Para resolver esta restricción métrica y determinar con precisión qué factor ejerce la mayor influencia sobre el Rendimiento, se

transformaron los datos a puntuaciones estandarizadas Z (media 0, varianza 1), obteniendo los coeficientes Beta (β^*) (Tabla 8).

Tabla 8. Coeficientes de Estandarización.

Variable	Coeficiente Beta (Estandarizado β^*)	Valor p
Peso Auto	-0.7338	< 0.001
Tamaño Motor	-0.3299	< 0.001
Largo Auto	0.2096	< 0.001

La evaluación basada en coeficientes Beta estandarizados permite concluir que la ingeniería orientada a la optimización del rendimiento combustible debe priorizar la reducción de peso del vehículo (aligeramiento de materiales) por sobre la reducción de la cilindrada del motor, dado que el impacto de la masa sobre la eficiencia es 2.22 veces mayor que el del tamaño del motor, y 3.50 veces más influyente que la ganancia obtenida mediante proporciones longitudinales.

Conclusiones.

El desarrollo del presente proyecto permitió consolidar un modelo de regresión lineal múltiple válido y estadísticamente significativo para explicar las variaciones del rendimiento de combustible en función de características de ingeniería automotriz.

En el plano metodológico, se demostró la importancia crítica que posee la depuración estratégica de observaciones influyentes. La eliminación de tres observaciones atípicas mediante el criterio de residuales estandarizados incrementó la capacidad explicativa del modelo, elevando el R^2_{adj} de 0.736 a 0.784. Tanto la linealidad global como la distribución normal de los residuos (confirmada mediante la prueba de Shapiro-Wilk con un valor p de 0.346) y la homocedasticidad uniforme en la varianza validan analíticamente la inferencia del modelo, asegurando que los coeficientes obtenidos son lineales, insesgados y óptimos.

Al eliminar la incomparabilidad de escalas entre predictores por medio del cálculo de coeficientes estandarizados, se concluye que la masa del vehículo es el factor con mayor influencia sobre la eficiencia de combustible, exhibiendo un impacto negativo dominante ($\beta^* = -0.7338$). La influencia del peso es 2.22 veces superior al impacto mecánico derivado de la cilindrada del motor ($\beta^* = -0.3299$). Asimismo, el aislamiento de estos efectos físicos permitió capturar la contribución marginal positiva del largo del vehículo ($\beta^* = 0.2096$), la cual sugiere ventajas aerodinámicas o de proporciones de diseño geométrico que favorecen sutilmente el rendimiento.

Este estudio aporta evidencia cuantitativa sólida que establece que cualquier esfuerzo de optimización enfocado en maximizar la eficiencia en millas por galón (MPG) debe priorizar el aligeramiento de materiales y la reducción de la masa vehicular total.

Referencias.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to linear regression analysis* (5th ed.). John Wiley & Sons.