PROYECTO REGRESIÓN LINEAL SIMPLE: ANALISIS DEL MODELO MÁS ÓPTIMO PARA LA VARIABLE DE RESPUESTA PESO Y LAS VARIABLES EXPLICATIVAS ALTURA, LONGITUD DE PIE Y CIRCUNFERENCIA DE LA CABEZA

LEM. Geiler Ademar Chable Cool

1. Introducción

Se realizaron tres análisis de regresión lineal simple para modelar el **peso** en función de la **altura**, la **longitud del pie** y la **circunferencia de la cabeza**, respectivamente. El estudio se basó en una muestra de 28 observaciones, evaluando individualmente la capacidad explicativa de cada variable antropométrica.

Se llevó a cabo un análisis descriptivo inicial para caracterizar el comportamiento de la muestra y sus variables. Posteriormente, se procedió con un análisis inferencial para validar la robustez y significancia de los modelos propuestos. Durante la etapa descriptiva, se integró la totalidad de la muestra bajo un enfoque multivariado, asumiendo que las mediciones corresponden a una unidad de observación única. Finalmente, tras identificar la relación con mayor poder explicativo, se realizó un tratamiento de datos atípicos mediante la remoción de una observación influyente, logrando así optimizar el ajuste y la precisión del modelo final.

2. Metodología

Para el desarrollo de este proyecto se siguió un enfoque cuantitativo y correlacional, el análisis se dividió en tres fases.

- **Fase 1: Preparación y limpieza de datos.** Se realizó una inspección de la muestra (n=28) para identificar valores nulos y datos atípicos. Se utilizó la librería *pandas* de Python para el tratamiento de datos. Se observó duplicación de filas y columnas con valores nulos, los cuales fueron eliminados.

- **Fase 2: Análisis Descriptivo y de Correlación.** Se evaluó la relación lineal entre la variable dependiente (Peso) y las independientes (Altura, Longitud de pie y Circunferencia de cabeza) mediante coeficientes de correlación de Pearson y diagramas de dispersión, análisis realizado a través de R y RStudio.

- **Fase 3: Modelado Estadístico.** Se ajustaron modelos de Regresión Lineal Simple (RLS) mediante el método de Mínimos Cuadrados Ordinarios (OLS). Se realizó una

re-estimación del modelo más óptimo (Peso vs Altura) tras la exclusión de un valor atípico identificado mediante el análisis de residuales. Finalmente, se verificaron los supuestos de linealidad, homocedasticidad y normalidad de los residuales (esta última mediante la prueba de Shapiro-Wilk) para el mejor modelo.

Por otra parte,

- **Software utilizado:**

  RStudio para el análisis descriptivo, visualización de gráfico de caja y pivote, así como la visualización del mapa de calor de correlación y, gráficos de dispersión con su modelo de regresión lineal simple.

  Python (en el entorno Google Colab) con las librerías pandas para gestión de datos, seaborn para visualización y statsmodels para el cálculo inferencial.

- **Nivel de Confianza:** Se trabajó con un nivel de confianza estándar $\alpha = 0.05$

3. Resultados

3.1.1 Análisis Descriptivo.

Resultados en R de resumen de las variables "Peso, Altura, Longitud del Pie & Circunferencia de Cabeza", visualizadas en la tabla 1.

Tabla 1. Resumen estadístico de las variables involucradas en el problema

Variable / Análisis Descriptivo	Peso	Altura	Longitud Pie	Circunferencia Cabeza
Valor Mínimo	47	144	21	44.50
Mediana	63	162.5	25	56
Media	64.89	163.3	25.46	55.58
Valor Máximo	98	181	33	63

3.1.2 Análisis en Relación a las Medidas de Tendencia Central

La muestra presenta una distribución variada en todas sus dimensiones físicas, destacando los siguientes promedios:

- **Peso Corporal:** El peso promedio se sitúa en 64.89 kg, con una mediana de 63.00 kg.

- **Estatura:** La altura media de los sujetos es de 163.3 cm, oscilando entre un mínimo de 144 cm y un máximo de 181 cm.
- **Dimensiones Extremas:** La longitud del pie promedio es de 25.46 cm y la circunferencia de la cabeza es de 55.58 cm.

3.1.3 Análisis en Relación a la Variabilidad y Dispersión

- **Rango de Peso:** Existe una diferencia considerable de 51 kg entre el individuo más ligero (47 kg) y el más pesado (98 kg).
- **Consistencia en Dimensiones Craneales:** La circunferencia de la cabeza es la medida más estable, con una diferencia de solo 18.5 cm entre el valor mínimo y máximo, lo que sugiere una menor variabilidad biológica en esta área comparada con el peso.

3.1.4 Identificación de Outliers

Por otra parte, visualizamos la representación gráfica de una caja y pivote por cada variable con la intención de identificar outliers, éstas se visualizan en la ilustración 1.

Ilustración 1. Gráficos de caja y pivote por cada una de las variables

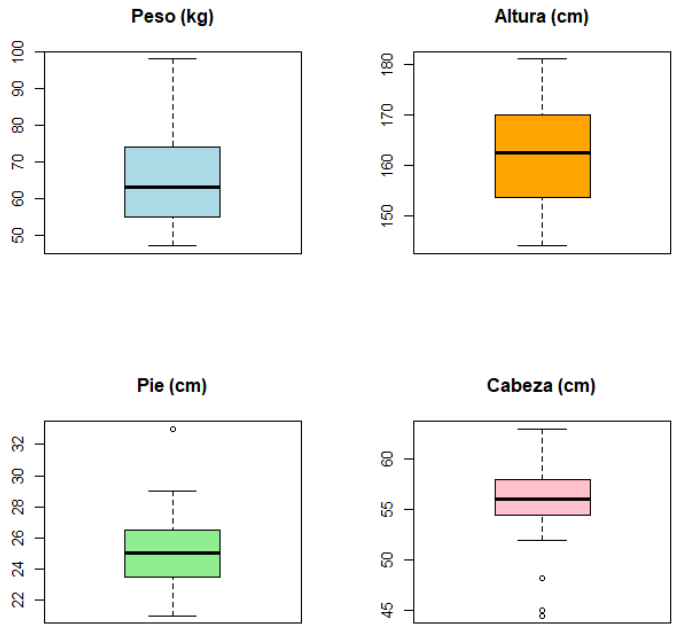

Observaciones:

- **Pie (cm) y Cabeza (cm):** Presentan valores atípicos. En el gráfico de **Pie**, hay un valor inusualmente alto (cerca de 33 cm). En **Cabeza**, se observan varios valores atípicos en la parte inferior (alrededor de 45-48 cm).
- **Peso y Altura:** No muestran valores atípicos evidentes fuera de los bigotes.

Debido a la naturaleza multivariada del estudio, se optó por conservar los registros con valores atípicos en las variables 'Longitud del Pie' y 'Circunferencia de la Cabeza' para no reducir el tamaño de la muestra.

3.1.4 Correlación

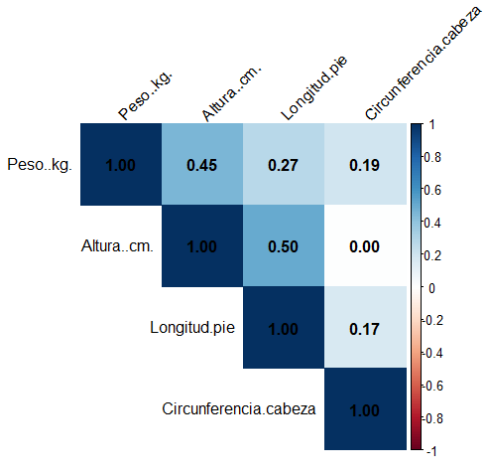

Ilustración 2. Mapa de calor de las correlaciones de las variables

Se calculó la matriz de correlación de Pearson para evaluar las relaciones lineales entre las variables antropométricas. Los resultados indican que la asociación más significativa se presenta entre la **Altura y la Longitud del pie (r = 0.50)**, seguida de la relación entre **Peso y Altura (r = 0.45)**, ambas clasificadas como correlaciones positivas de magnitud moderada.

Por el contrario, se observó una ausencia de relación lineal entre la **Altura y la Circunferencia de la cabeza (r = 0.00)**, lo que sugiere que estas variables operan de manera independiente en la muestra estudiada. Las correlaciones restantes mostraron asociaciones débiles, inferiores a 0.30. Estos hallazgos justifican la exploración de la Altura como una variable predictora en modelos de regresión lineal simple para el Peso o la Longitud del pie.

3.2 Análisis Estadístico Inferencial

3.2.1 Modelo de Regresión Lineal Simple

Se establecen 3 modelos de regresión lineal simple, donde la variable de respuesta “Peso” es modelado por cada variable predictora “Altura”, “Longitud de Pie” & “Circunferencia de la Cabeza”. En donde se analiza cada modelo, para poder decidirse en el más significativo.

Previo a los modelos algebraicos, se visualiza con R el modelo de regresión lineal simple de cada una de las relaciones de variable predictora y variable de respuesta.

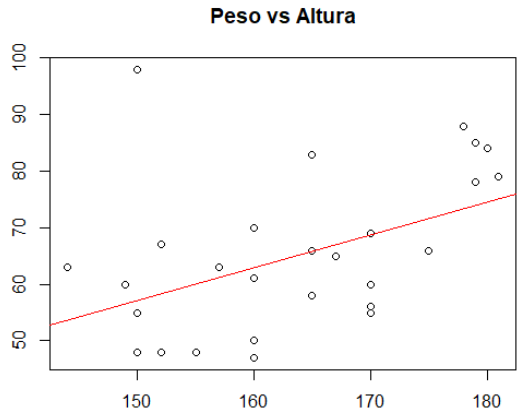

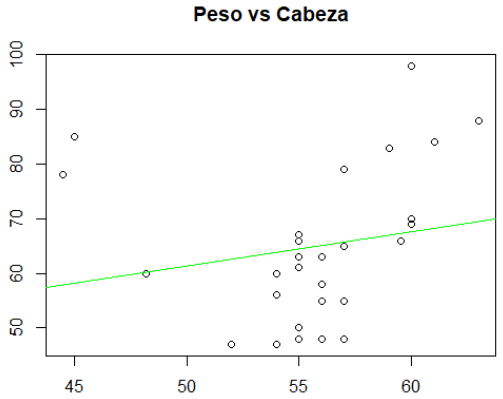

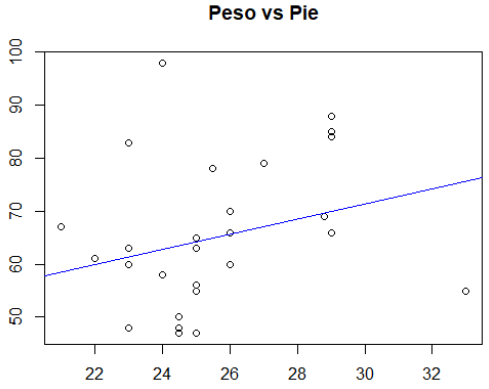

Se puede visualizar que los tres modelos parecieran, en cierto modo, útiles. Sin embargo, el análisis descriptivo previo nos da observaciones importantes para no considerar el modelado de Peso vs Cabeza y Peso vs Pie, por lo que, un análisis inferencial a los parámetros del modelo de regresión lineal simple nos brindará información más certera.

Con apoyo de R, se obtuvieron los parámetros, inferencias de los parámetros y la bondad de ajuste de cada modelo. En la tabla 2 se observan los resultados.

Variables Relacionadas	Modelo Regresión Lineal Simple	Bondad de Ajuste R^2
Peso – Altura	$\hat{y}_1 = -29.9172 + 0.5805x$	0.2029
Peso – Longitud de Pie	$\hat{y}_2 = 28.6088 + 1.4253x$	0.07401
Peso – Circunferencia de la Cabeza	$\hat{y}_3 = 30.0139 + 0.6276x$	0.0362

Tabla 2. Modelos de Regresión Lineal Simple y Bondad de Ajuste

Podemos observar en la tabla, que los modelos $\hat{y}_2$ & $\hat{y}_3$, no tienen una buena bondad de ajuste, esto aunado a la correlación. Es decir, los modelos explican la variabilidad en un porcentaje bajo, siendo **7.401%** y **3.62%** para las relaciones **Peso - Longitud** y **Pesos – Circunferencia de Cabeza,** respectivamente. Esto apunta a, un riesgo para usar dichos modelos para fines de explicación. En contra parte, el modelo **Peso – Altura**, explica un 20.2% de variabilidad, lo cual se considera como una buena medida para ser usado como modelo de predicción, sin embargo, este podría aumentar si, se considera la eliminación de outlier.

Variables Relacionadas	Inferencia B_0 (Valor p)	Inferencia B_1 (Valor p)
Peso – Altura	0.4253	0.0162
Peso – Longitud de Pie	0.269	0.161
Peso – Circunferencia de la Cabeza	0.401	0.329

Tabla 3. Inferencia a Coeficientes del Modelo de Regresión Lineal Simple

La tabla 3 nos vuelve a confirmar que los modelos $\hat{y}_2$ & $\hat{y}_3$ no son suficientes para considerarlos y en consecuencia, concluir que las variables longitud de pie y circunferencia de cabeza no son variables explicativas de la variable de respuesta peso.

Por otra parte, la inferencia del coeficiente B_1 del modelo Peso – Altura, nos da como resultado que el parámetro B_1 es estadísticamente diferente de cero, por lo que, dicho modelo es útil en comparación de los otros dos. En consecuencia, nos centramos en el modelo de regresión lineal simple Peso – Altura.

3.2.2 Análisis Modelo Peso – Altura

El siguiente gráfico de dispersión, nos mostrará el modelo de regresión lineal simple entre la variable predictora Altura y la variable de respuesta Peso. Además de que, el área sombreada representa el comportamiento de los residuales. Por otra parte, el gráfico de

residuales nos visualizará el comportamiento de los errores del modelo de regresión lineal Peso-Altura.

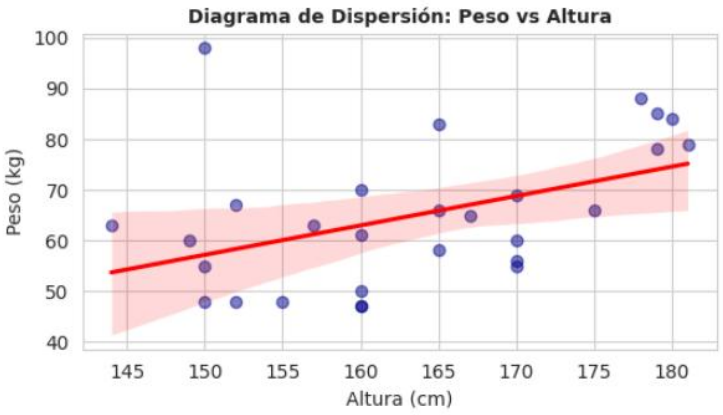

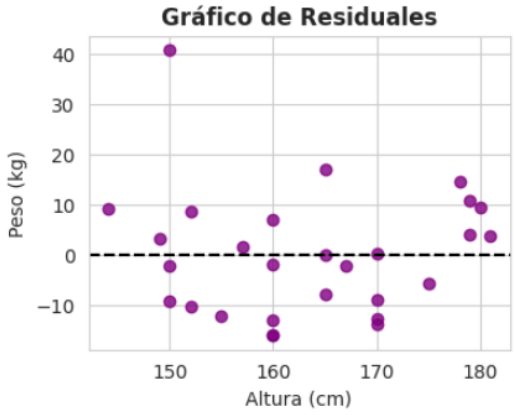

En ambos gráficos podemos observar puntos importantes a considerar.

- Un outlier está afectando la significancia y utilidad de nuestro modelo. Es decir, el residuo que hay en la persona de 150cm es tan grande que infla el Error Cuadrático Medio y hace que nuestra bondad de ajuste sea mucho más baja de lo que podría ser.
- Por otra parte, si ignoramos el outlier en el gráfico de residuales, estos parecieran estar bien distribuidos, en donde el supuesto de los errores residuales de varianza constante se estaría cumpliendo de manera más eficaz. Ante esto, la eliminación del outlier nos permitirá tener un modelo más eficiente.

Después de considerar la eliminación de la fila en nuestra base de datos que incluía el outlier, tenemos el siguiente gráfico con una mejor modelación.

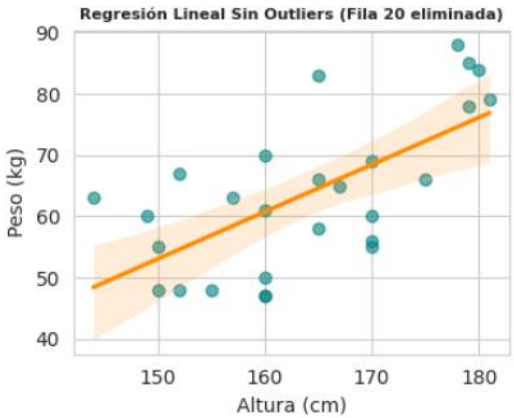

En la visualización de nuestro nuevo gráfico sin outlier verificamos que se cumplen los supuestos de un modelo de regresión lineal simple.

La relación es lineal. Si los puntos formaran una curva, el modelo de línea recta no sería el adecuado. Por otra parte, La constancia de la varianza de los errores se evaluó mediante la inspección visual del gráfico de residuales frente a los valores ajustados. Tras la remoción del dato atípico, los residuales mostraron una dispersión uniforme y aleatoria alrededor del eje horizontal (cero), sin presentar patrones de embudo o tendencias sistemáticas. Esto confirma que el error del modelo no depende de la magnitud de la altura, cumpliendo así con el supuesto de homocedasticidad necesario para la validez de las pruebas de inferencia.

Por último, la normalidad de los residuales se validó a través de una prueba de Shapiro Wilk. Con Python se obtuvo el siguiente valor p para la prueba de Shapiro-Wilk, donde confirmamos que los residuales siguen una distribución normal. A continuación, se muestra la salida del código en la siguiente imagen:

```
Estadístico de Shapiro: 0.9543
P-valor: 0.2720
Veredicto: Los residuales siguen una distribución normal (No se rechaza H0)
```

Prueba Shapiro-Wilk con Python & Scipy

3.2.3.1 Modelo Regresión Lineal Peso – Altura (Después de eliminación outlier)

Considerando la eliminación de este valor atípico y la normalidad de los errores residuales, procedemos a ajustar un modelo de regresión lineal simple para la variable de respuesta Peso y la variable predictora Altura con Python, obteniendo la siguiente salida.

```
                            OLS Regression Results
==============================================================================
Dep. Variable:              Peso (kg)   R-squared:                       0.429
Model:                            OLS   Adj. R-squared:                  0.406
Method:                 Least Squares   F-statistic:                     18.75
Date:                Sun, 22 Mar 2026   Prob (F-statistic):           0.000211
Time:                        16:59:07   Log-Likelihood:                -98.637
No. Observations:                  27   AIC:                             201.3
Df Residuals:                      25   BIC:                             203.9
Df Model:                           1
Covariance Type:            nonrobust
==================================================================================
                  coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------
const         -62.4233     29.177     -2.139      0.042    -122.514      -2.333
Altura (cm)     0.7697      0.178      4.330      0.000       0.404       1.136
==============================================================================
```

Resultados de Python para Modelo de Regresión Lineal después de la eliminación del outlier.

En la tabla 4 se sintetiza los resultados relevantes.

Modelo de Regresión Lineal: $\hat{y}_4 = -62.4233 + 0.7697x$				
Valor p B_0	Valor p B_1	Bondad de Ajuste R^2	Intervalo de Confianza B_0	Intervalo de Confianza B_1
0.042	Aproximadamente 0	0.429	[-122.514, -2.333]	[0.404, 1.136]
Tabla 4. Modelo Peso - Altura después de la eliminación de un outlier				

De acuerdo a la inferencia del nuevo modelo de Regresión Lineal Simple de Peso – Altura, podemos observar que los parámetros B_0 & B_1 ambos tienen un rechazo a la hipótesis nula y por consiguiente son diferentes de cero. De igual modo, la bondad de ajuste es mayor, es decir la explicación de la variabilidad del modelo se ajusta un 42.9%. Finalmente, los valores estimados se encuentran dentro del intervalo de confianza del 95%, en donde los parámetros B_0 & B_1 son los mejores estimadores para el modelo de regresión lineal ya que, se cumplen los siguientes principios.

- Son combinaciones lineales de las observaciones.
- Son estimadores insesgados con varianza mínima.

En consecuencia, como se menciona en Montgomery et al. (2006): “Los estimadores por mínimos cuadrados son los estimadores lineales insesgados óptimos, donde “óptimos” implica que son de varianza mínima” (p. 20)

Considerando que, Python y su librería Statsmodels recurre a mínimos cuadrados ordinarios para la estimación de los parámetros B_0 & B_1.

Por otra parte, si dicho modelo nos quisiera explicar el comportamiento del peso de las personas, convendría delimitar los valores posibles de “x”, ya que valores muy pequeños se saldrían de resultados coherentes. Podríamos considerar los valores de “x” en el intervalo de [110cm, 272cm] que corresponderían a valores para la variable $\hat{y}_4$ en el intervalo [22.2437kg, 146.9351kg]. Considerando estos intervalos como datos racionales, donde 22.2437kg correspondería un caso de bajo peso para una altura de 1.10 metros y 146.9351kg correspondería a un caso normal de peso para una persona de 2.72 metros, que, en la realidad, es la altura máxima registrada en la humanidad.

3.2.3.2 Interpretación de los Parámetros ($\hat{y}_4 = -62.4233 + 0.7697x$)

Considerando el modelo de regresión lineal simple de la tabla 4, la interpretación de los parámetros B_0 & B_1 son los siguientes:

- El intercepto (B_0) representa el valor esperado del peso cuando la altura es cero. En este contexto biológico, el valor de -62.42 kg no tiene una interpretación práctica directa, ya que no existen individuos con altura de 0 cm. Su función es puramente matemática para ajustar la posición de la recta en el plano cartesiano dentro del rango de los datos observados.
- El coeficiente de regresión (B_1) indica que, por cada centímetro adicional de altura en un individuo, se espera un incremento promedio de 0.7697 kg en el peso corporal. Dado que el valor p asociado es menor a 0.05, podemos afirmar que la altura es un predictor estadísticamente significativo para el peso en esta muestra.
- De igual modo, para B_1, se puede interpretar que al comparar dos individuos con un centímetro de diferencia en la altura, se espera un incremento promedio de 0.7697kg en el peso corporal.

4. Conclusiones

4.1 Estadísticas Descriptiva

Se selecciona la **Altura** como variable explicativa debido a su correlación moderada (r = 0.45) y su distribución simétrica, lo que minimiza el riesgo de introducir sesgos por valores

atípicos en la variable independiente, asegurando un modelo más robusto para explicar y predecir el **Peso**.

4.2 Estadística Inferencial

Se realiza inferencia a los parámetros de los tres modelos de regresión lineal simple, en donde se concluye que el único modelo adecuado y pertinente para predicciones es la relación Peso – Altura. Debido a que presentó una relación estadísticamente significativa (valor p < 0.05) y un mayor coeficiente de determinación en comparación con las demás variables.

Se decide eliminar el valor atípico (150cm, 98kg) para tener un mejor modelo ajustado ($\hat{y}_4 = -62.4233 + 0.7697x$). En el cuál se siguen teniendo resultados positivos en la inferencia de los parámetros con la diferencia que la explicación de la variabilidad aumenta de 20.29% a 42.9%. Esto implica que el modelo sin el dato atípico logra explicar un 22.6% adicional de la variabilidad del peso basándose en la altura.

4.3 Decisiones Finales

De acuerdo al análisis descriptivo e inferencial de nuestras variables explicativas “Altura”, “Longitud de Pie” & “Circunferencia de la Cabeza” en relación a la variable de respuesta “Peso”, se concluye que la mejor variable para ajustar un modelo de regresión lineal simple es el de Altura – Peso $\hat{y}_1 = -29.9172 + 0.5805x$ con un $R^2 = 20.29\%$.

Considerando la eliminación de un dato atípico, teniendo en cuenta que la muestra es pequeña y el caso de valor extremo con alto influencia (persona que mide 150cm y peso 98kg) pudiese afectar la explicación de nuestro modelo, se realizo un ajuste nuevo de nuestras variables Altura – Peso, teniendo como modelo $\hat{y}_4 = -62.4233 + 0.7697x$ con un $R^2 = 42.9\%$ y errores residuales distribuyéndose de manera normal.

La mejora sustancial del coeficiente de determinación (R^2) del 20.29% al 42.9% tras la depuración de la muestra sugiere que el modelo de Altura-Peso posee una capacidad explicativa moderada-alta para una muestra de carácter biológico, validando su uso para fines descriptivos en este grupo de estudio.

5. Referencias Bibliográficas:

Montgomery, D. C., Peck, E. A., y Vining, G. G. (2006). *Introducción al análisis de regresión lineal* (3ª ed.). Editorial Continental.